Чернівецький національний університет імені Юрія Федьковича

Факультет математики та інформатики

ЩОДЕННИК
ВИРОБНИЧО-НАУКОВОЇ ПРАКТИКИ
МАГІСТРАНТА

Кацап Владислав Геннадійович

602 група

за період з «12» жовтня по «31» жовтня 2026 року

Місце практики: Загальнофакультетська спеціалізована науково-дослідна лабораторія з дослідження та розробки систем автоматизованого проектування «Development of CAD/CAM/CAE - systems».

Керівник: Унгурян Галина Михайлівна, кандидат фізико-математичних наук (доктор філософії), вчене звання — доцент.

Тема роботи: «Прикладний статистичний аналіз даних із використанням мови програмування R».

Дата (період)	Вид виконаної роботи	Відмітка про виконання
12–31.10. 2026	1. Ознайомлення із завданням практики. Підготовка програмного середовища та набору даних для статистичного аналізу.	Виконано
12–31.10. 2026	2. Дослідження основних характеристик даних із використанням методів описової статистики.	Виконано
12–31.10. 2026	3. Побудова графіків для наочного представлення даних. Аналіз особливостей розподілу досліджуваних показників.	Виконано
12–31.10. 2026	4. Дослідження взаємозв’язків між показниками за допомогою методів кореляційного аналізу.	Виконано
12–31.10. 2026	5. Побудова регресійної моделі для аналізу залежностей і прогнозування значень.	Виконано
12–31.10. 2026	6. Перевірка якості побудованої моделі та працездатності програми. Оцінювання отриманих результатів.	Виконано
12–31.10. 2026	7. Узагальнення результатів роботи та формулювання висновків. Підготовка звіту з графіками й скриншотами виконання програми.	Виконано

Підпис магістранта _____ В. Г. Кацап

Підпис керівника _____ Г. М. Унгурян

У щоденнику наведено роботи за період практики. Оцінку кожного етапу виставляє керівник.

Факультет математики та інформатики

Кафедра прикладної математики та інформаційних технологій

ЗВІТ

про проходження виробничо-наукової практики магістранта

Кацап Владислав Геннадійович

602 група

У період з «12» жовтня по «31» жовтня 2026 року проходив виробничо-наукову практику у загальнофакультетській спеціалізованій науково-дослідній лабораторії з дослідження та розробки систем автоматизованого проектування «Development of CAD/CAM/CAE - systems» факультету математики та інформатики.

Керівник виробничо-наукової практики: Унгурян Галина Михайлівна, кандидат фізико-математичних наук (доктор філософії), вчене звання — доцент.

Тема: «Прикладний статистичний аналіз даних із використанням мови програмування R».

За період практики мною виконано такі види робіт

№	Зміст роботи	Ф-т	Дата (період)	Підпис викладача
1	Завантажив CSV через readr, перевірив пропуски й дублікати. Вилучив 42 неповні рядки; перевів одиниці температури та вітру.	ФМІ	12–31.10. 2026	
2	Обчислив сім описових показників для чотирьох числових змінних. Зберіг усі моди при однаковій частоті значень.	ФМІ	12–31.10. 2026	
3	Побудував гістограми, boxplot і діаграми розсіювання за допомогою ggplot2; позначив можливі викиди за правилом 1,5 IQR.	ФМІ	12–31.10. 2026	
4	Розрахував кореляції Пірсона та Спірмена для шести пар змінних; для Пірсона — довірчі інтервали й p-значення з BH-корекцією.	ФМІ	12–31.10. 2026	
5	Навчив множинну лінійну регресію на перших 88 записах за часом. Обчислив прогнози й 95 % прогнозні інтервали.	ФМІ	12–31.10. 2026	
6	Перевірив модель на останніх 23 записах. Дослідив значущість коефіцієнтів, залишки, VIF і відстань Кука.	ФМІ	12–31.10. 2026	
7	Виконав п’ять інтеграційних тестів. Підготував очищені дані, 15 таблиць CSV, 8 графіків, модель RDS і звіт зі скриншотами.	ФМІ	12–31.10. 2026	

Результати виконаної роботи

Мною розроблено модуль analysis.R для імпорту й очищення даних, статистичних розрахунків, візуалізації та прогнозування. Роботу виконано мовою R у RStudio з пакетами readr, dplyr і ggplot2. Набір airquality містить щоденні спостереження якості повітря в Нью-Йорку за травень–вересень 1973 року.

У 153 початкових записах виявлено 44 пропущені значення у 42 рядках; точних дублікатів і некоректних рядків не виявлено. Після очищення залишилося 111 спостережень. Середня концентрація озону становить 42,10 ppb, медіана — 31 ppb, стандартне відхилення — 33,28 ppb.

Озон має додатний зв’язок із температурою (r = 0,6985) і сонячною радіацією (r = 0,3483) та від’ємний зі швидкістю вітру (r = −0,6125). Коефіцієнти трьох предикторів регресії статистично значущі на рівні 0,05. Ці залежності описують асоціації та не доводять причинного впливу.

Показник	Значення
Навчальна / тестова вибірка	88 / 23 спостереження
R^2 на навчальній вибірці	0,6197
R^2 на тестовій вибірці	−2,6784
RMSE на тестовій вибірці	18,7735 ppb
MAE на тестовій вибірці	15,5773 ppb

Навчальний R^2 показує, що модель пояснює близько 62 % варіації озону в навчальних даних. Від’ємний тестовий R^2 означає гірший результат порівняно з ретроспективним прогнозом середнім значенням самого тестового набору. Тест Шапіро–Вілка виявив відхилення залишків від нормальності (p = 0,0000563). Тому модель придатна для навчального дослідження залежностей, а її практичне застосування потребує нових даних і додаткової перевірки.

Відгуки магістранта щодо проведення і змісту практики

Під час роботи я закріпив навички обробки даних мовою R та роботи в RStudio. Навчився поєднувати статистичні показники з графічним аналізом і перевіряти модель на окремій тестовій вибірці. Зіставлення навчального й тестового R^2 показало, що добрий опис навчальних даних не гарантує точного прогнозування. Подальшу роботу доцільно спрямувати на нелінійні залежності, сезонність і новіші спостереження.

Дата оформлення: 04 листопада 2026 року

Підпис магістранта _____ Кацап Владислав Геннадійович

Підпис керівника _____ Унгурян Галина Михайлівна

Затверджено на засіданні кафедри прикладної математики та інформаційних технологій.

Протокол № _____ від «____» _____ 2026 р.

Додаток А Код програми в RStudio

Основний файл analysis.R містить функцію run_analysis. На скриншоті показано поділ даних за часом на навчальну й тестову вибірки, навчання лінійної регресії та збереження її коефіцієнтів і моделі.

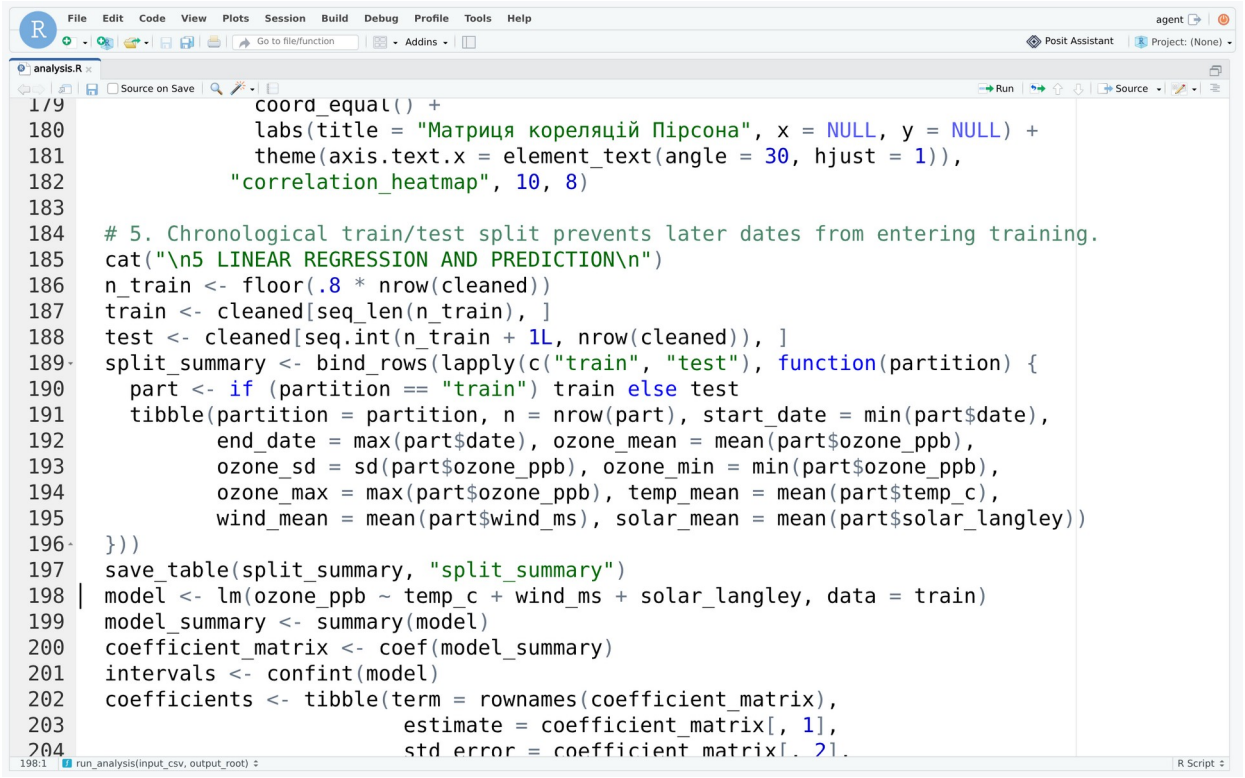


Рисунок А.1 — Фрагмент робочого коду analysis.R у RStudio

Порядок запуску програми

Відкрити Practice_R.Rproj у RStudio та виконати в консолі команду:

```
source("analysis.R", encoding = "UTF-8")
```

Команда завантажує весь файл, визначає функцію run_analysis і запускає аналіз в інтерактивній сесії RStudio. Для повторного запуску слід виконувати весь файл кнопкою Source. Програма послідовно виконує сім етапів аналізу та зберігає оброблені дані, таблиці, графіки й модель у відповідних каталогах проєкту.

Підготовлені матеріали

Код — analysis.R; вхідні дані — data/raw/airquality.csv; очищені дані — data/processed/airquality_clean.csv. Статистичні таблиці збережено у results/tables/, графіки — у results/figures/, модель — у results/models/ozone_linear_model.rds.

Повний технічний звіт із вісьмома графіками: reports/Practice_R_Report.docx і reports/Practice_R_Report.pdf.

Додаток Б Результати виконання програми

Скриншот консолі RStudio відображає фактичні результати аналізу: обсяг очищених даних, розміри вибірок, навчальний і тестовий R^2 та похибки прогнозування.

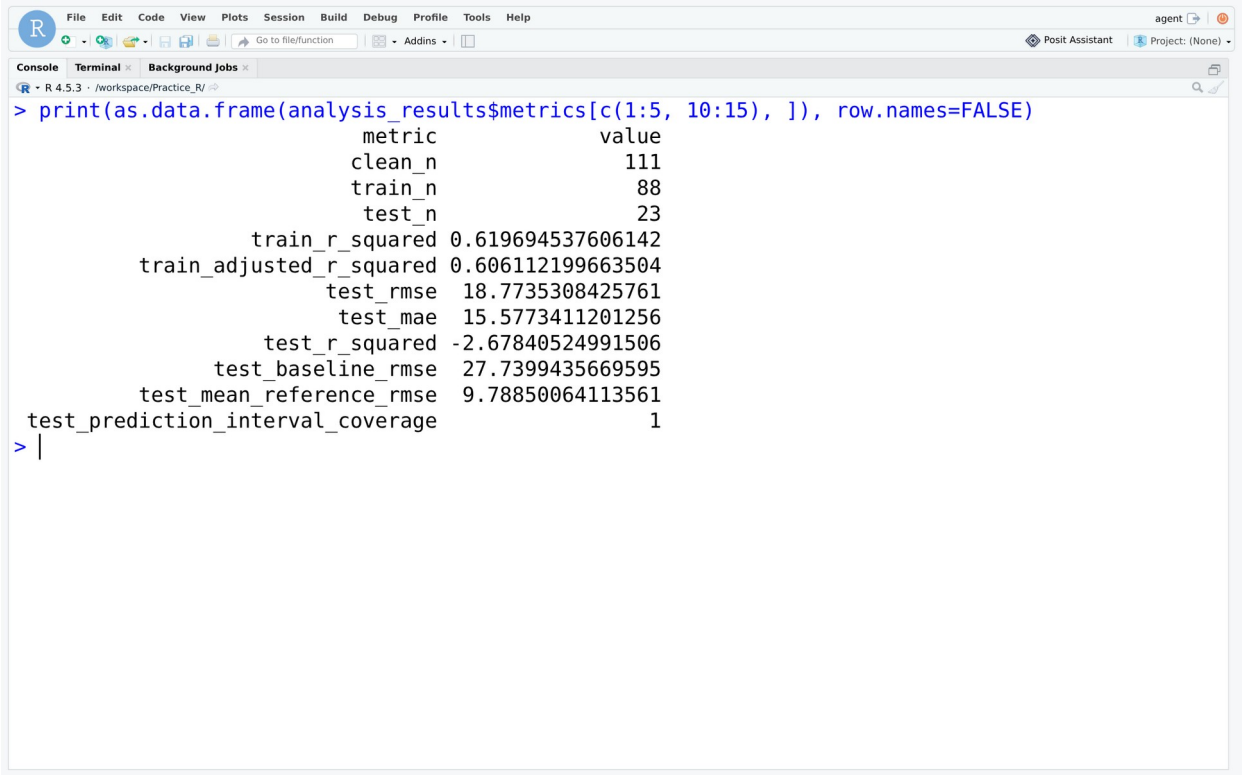


Рисунок Б.1 — Результати виконання analysis.R у консолі RStudio

Перевірки працездатності

Успішно виконано п’ять інтеграційних перевірок: відхилення неправильної структури CSV; виявлення помилкових числових значень; відхилення набору з менш ніж 50 коректними записами; очищення тестових дублікатів, фізично некоректних значень і неможливих дат; відтворення прогнозів збереженою моделлю. Журнал перевірок — results/test-output.txt.

Окремо виконано вісім перевірок середовища R, зокрема роботи з CSV, PNG, матрицями та компіляції розширень C, C++ і Fortran. Ці перевірки підтверджують працездатність середовища, але не є оцінкою точності статистичної моделі.

Джерела та відтворюваність

Дані: datasets::airquality, документація пакета datasets у R. Методи: документація stats::lm, stats::cor.test, stats::predict.lm та stats::shapiro.test. Параметри середовища зафіксовано у results/session-info.txt та environment/conda-linux-64.lock.

Репозиторій роботи:
https://github.com/VladyslavGennadijovych/Practice_R

Додаток В Графічні результати статистичного аналізу

Графіки побудовано за 111 очищеними спостереженнями. Гістограми показують форму розподілів, а діаграми розмаху — медіани, розкид значень і можливі викиди.

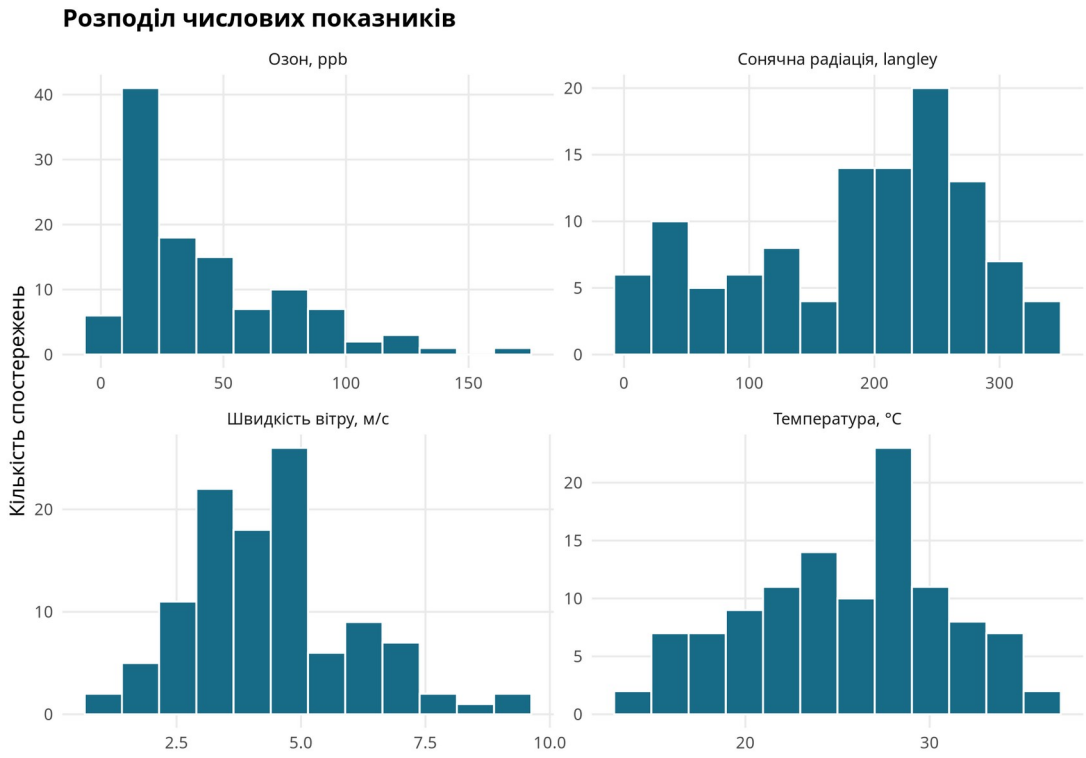


Рисунок В.1 — Гістограми розподілу досліджуваних показників

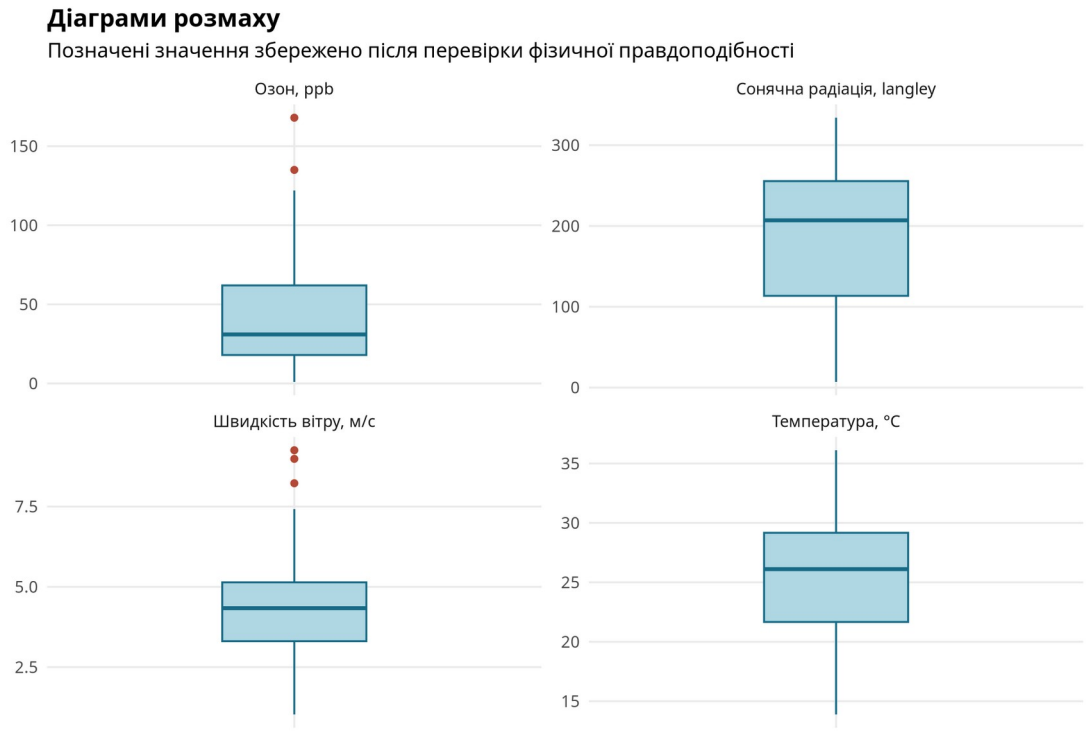


Рисунок В.2 — Діаграми розмаху досліджуваних показників

Додаток В Взаємозв’язки між показниками

Вищі значення озону пов’язані з вищою температурою та нижчою швидкістю вітру. Матриця містить коефіцієнти кореляції Пірсона; виявлені зв’язки не доводять причинності.

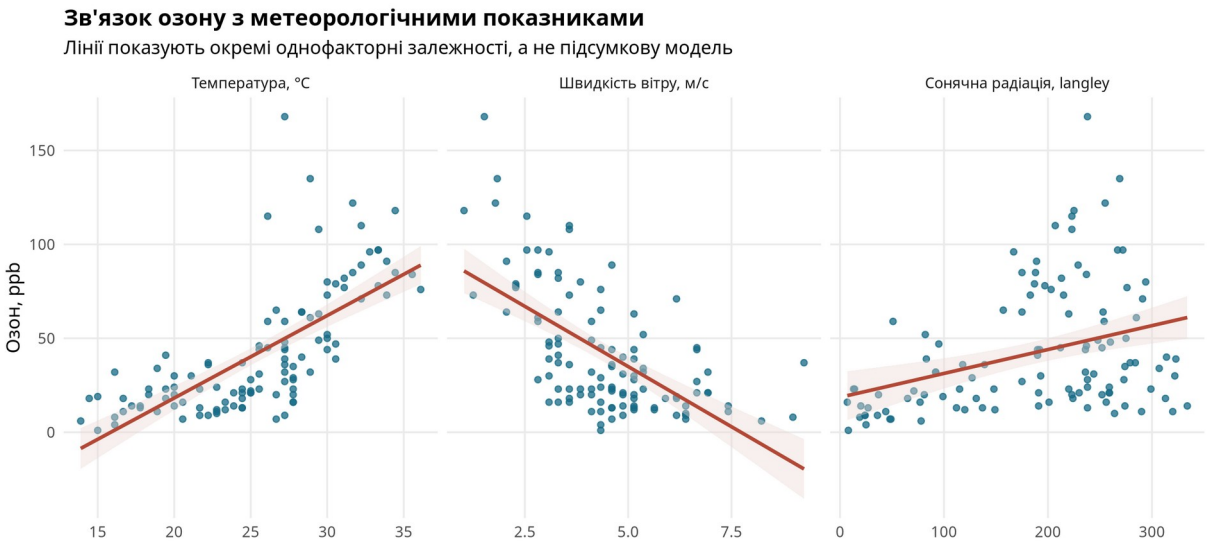


Рисунок В.3 — Зв’язок концентрації озону з іншими показниками



Рисунок В.4 — Кореляційна матриця досліджуваних показників

Додаток В Оцінювання результатів прогнозування

Модель перевірено на 23 відкладених спостереженнях, які не використовувалися для навчання. Графік зіставляє фактичну концентрацію озону з прогнозом моделі.



Рисунок В.5 — Фактичні та прогнозовані значення озону на тестовій вибірці

Пунктирна діагональ відповідає точному збігу прогнозу з фактичним значенням. Віддалення точок від цієї лінії показує похибки прогнозування. RMSE становить 18,7735 ppb, тестовий R^2 — −2,6784.

Від’ємний тестовий R^2 і помітні відхилення прогнозів обмежують практичне застосування моделі. Для підвищення її прогнозної якості потрібні додаткові дані та перевірка альтернативних моделей. Усі графіки збережено в каталозі results/figures/.